

Research Notes

 **Tao Zhu**

 **zhutaoer@outlook.com**

创建于: 2025 年 12 月 24 日

更新于: 2025 年 12 月 24 日

目录

1	正文示例章节	3
1.1	子章节标题	3
1.2	列表示例	3
1.3	英文字体展示	3
1.4	三线表示例	3
1.5	伪代码示例	5
2	代码示例	6
3	插图示例	7
4	彩色信息框示例	8

1 正文示例章节

这是一个简单的正文内容展示。你可以看到，普通文本使用的是默认的字号和对齐方式。你可以自由添加内容并调整格式。

1.1 子章节标题

这是一个子章节的内容展示。你可以在这里添加更多详细的文本内容，或者分段介绍不同的主题。

1.2 列表示例

这里是无序列表和有序列表的示例：

无序列表

- 项目 1
- 项目 2
- 项目 3

有序列表

1. 第一项
2. 第二项
3. 第三项

1.3 英文字体展示

The font I chose is Palatino, a classic serif font designed by German type designer Hermann Zapf in 1948. Compared to *Times New Roman*, Palatino has softer stroke contrasts and a more open character layout, making it less compact and serious, resulting in a more comfortable reading experience.

1.4 三线表示例

这是一个简单的三线表展示：

表 1: Notations

Symbol	Description
\mathcal{S}	State space of the embodied agent
\mathcal{A}	Discrete action space
$T(s' s, a)$	State transition function
$R(s, a)$	Reward function (negative distance to goal)
γ	Discount factor, $\gamma \in (0, 1)$
$V(s)$	Value function of state s
$\pi(s)$	Policy mapping states to actions
V^*	Optimal value function
π^*	Optimal policy
θ	Convergence threshold for value iteration
Δ	Maximum change in value function during iteration
s_{goal}	Target position in the environment
s_{pos}	Current position of the agent

*There are some variables that are not listed here and will be discussed in detail in each section.

1.5 伪代码示例

Algorithm 1: Value Iteration Algorithm for Embodied Navigation

Input: EMDP $\langle \mathcal{S}, \mathcal{A}, T, R, \gamma \rangle$, convergence threshold θ **Output:** Optimal value function V^* and policy π^*

```
1 Initialize  $V(s) \leftarrow 0$  for all  $s \in \mathcal{S}$ 
2 repeat
3    $\Delta \leftarrow 0$ 
4   for each  $s \in \mathcal{S}$  do
5      $v \leftarrow V(s)$ 
6      $V(s) \leftarrow \max_{a \in \mathcal{A}} [R(s, a) + \gamma \sum_{s'} T(s' | s, a) V(s')]$ 
7      $\Delta \leftarrow \max(\Delta, |v - V(s)|)$ 
8   end
                                     /* end for each state */
9 until  $\Delta < \theta$ 
                                     /* end repeat */

10 for each  $s \in \mathcal{S}$  do
11    $\pi^*(s) \leftarrow \arg \max_{a \in \mathcal{A}} [R(s, a) + \gamma \sum_{s'} T(s' | s, a) V^*(s')]$ 
12 end
                                     /* end for policy extraction */

13 return  $V^*, \pi^*$ 
```

2 代码示例

这是一个代码块的展示，支持语法高亮：

Listing 1: Python 代码示例

```
def hello_world():  
    print("Hello, World!")
```

3 插图示例



图 1: 示例图片

4 彩色信息框示例

定义 4.1: 具身马尔可夫决策过程 (EMDP)

一个具身马尔可夫决策过程定义为五元组 $\langle \mathcal{S}, \mathcal{A}, T, R, \gamma \rangle$, 其中:

- $\mathcal{S} = \mathbb{R}^2 \times [0, 2\pi)$ 为状态空间 (位置 + 朝向);
- $\mathcal{A} = \{\text{前进, 左转, 右转}\}$ 为离散动作空间;
- $T(s' | s, a)$ 为状态转移函数;
- $R(s, a) = -\|s_{\text{pos}} - s_{\text{goal}}\|$ 为稀疏奖励 (负欧氏距离);
- $\gamma \in (0, 1)$ 为折扣因子。

假设 4.1: 可观测性

智能体在每一步都能精确观测当前状态 $s_t \in \mathcal{S}$ 。

假设 4.2: 确定性动力学

状态转移是确定性的, 即 $s_{t+1} = f(s_t, a_t)$, 无环境噪声。

该算法的正确性由以下定理保证。

引理 4.1: 贝尔曼最优性

值函数 V^* 是贝尔曼最优算子 \mathcal{T} 的唯一不动点, 即 $V^* = \mathcal{T}V^*$, 其中

$$\mathcal{T}V(s) := \max_{a \in \mathcal{A}} \left[R(s, a) + \gamma \sum_{s'} T(s' | s, a) V(s') \right].$$

定理 4.1: 值迭代收敛性

值迭代算法生成的序列 $\{V_k\}$ 以指数速率收敛到 V^* , 即

$$\|V_k - V^*\|_{\infty} \leq \frac{2\gamma^k}{1-\gamma} \|V_1 - V_0\|_{\infty}.$$

证明. 由于状态空间 \mathcal{S} 在假设下为有限 (或可离散化), 且 $\gamma < 1$, 贝尔曼算子 \mathcal{T} 是 γ -压缩映射。由巴拿赫不动点定理, 迭代 $V_{k+1} = \mathcal{T}V_k$ 收敛到唯一不动点 V^* , 且误差界如上所述。□

例子 4.1: 2D 网格世界导航

考虑一个 5×5 的网格世界，机器人从左下角 $(0,0)$ 出发，目标为右上角 $(4,4)$ 。状态 $s = (x, y, \theta)$ ，其中 $\theta \in \{0, \pi/2, \pi, 3\pi/2\}$ 。动作 $\mathcal{A} = \{\text{前进}, \text{左转}, \text{右转}\}$ 控制朝向与位置。在 ?? 下，值迭代可精确计算到达目标的最短路径。